

Глава 1

Дебильник

1.1 Многомерное нормальное распределение

def. Стандартный гауссовский вектор — случайный n -мерный вектор $Z = (Z_1, Z_2, \dots, Z_n)$, координаты которого независимы и имеют распределение $\mathcal{N}(0, 1)$.

def. Гауссовский вектор (Нормальный вектор) — вектор, для которого существует матрица $\mathbf{A} \in \mathbb{R}^{n \times m}$, стандартный гауссовский вектор $Z \in \mathbb{R}^m$, и вектор $b \in \mathbb{R}^n$ такие, что $X = \mathbf{A}Z + b$.

def. Распределение нормального вектора $X \in \mathbb{R}^n - \mathcal{N}(\mu, \Sigma)$ или $\mathcal{N}_n(\mu, \Sigma)$, где $\mu = \mathbb{E}X$ и $\Sigma = \text{cov}(X)$.

def. Распределение хи-квадрат с n степенями свободы — распределение $\chi^2(n)$ величины $\chi^2 = Z_1^2 + Z_2^2 + \dots + Z_n^2$, где Z_1, Z_2, \dots, Z_n — независимы $\mathcal{N}(0, 1)$ величины.

def. Распределение Стьюдента с n степенями свободы — распределение $T(n)$ величины $\frac{\sqrt{n}X}{\sqrt{Y}}$, где $X \sim \mathcal{N}(0, 1)$, $Y \sim \chi^2(n)$ и независимы.

def. Распределение Фишера со степенями свободы n и m — распределение $F(n, m)$ величины $\frac{X/n}{Y/m}$, где $X \sim \chi^2(n)$, $Y \sim \chi^2(m)$ и независимы.

1.2 Условное матожидание

def. Условное матожидание $\mathbb{E}(Y \mid X)$ случайной величины Y при условии случайной величины X — такая измеримая функция g_0 величины X , при которой $\mathbb{E}(Y - g(X))^2$ минимально для всех измеримых функций g .

Условное матожидание — ортогональная проекция Y на линейное пространство всех измеримых функций X . То есть УМО — единственная измеримая функция, которая удовлетворяет условию ортогональности:

$$\forall g: \mathbb{E}(Y - \mathbb{E}(Y \mid X))g(X) = 0.$$

1.3 Статистическая модель, выборка

def. Статистическая модель — множество распределений \mathfrak{P} , которое, по нашему мнению, адекватно приближает \mathcal{P}_D .

def. Данные d — реализация случайного элемента D , имеющего распределение \mathcal{P}_D .

Статистические модели делят на:

- параметрические, если $\mathfrak{P} = \{\mathcal{P}_\theta \mid \theta \in \Theta \subset \mathbb{R}^k\}$.

Пример: $\mathfrak{P} = \{\mathcal{N}(\mu, \sigma^2) \mid \mu \in \mathbb{R}, \sigma^2 \geq 0\}$.

- непараметрические, если $\mathfrak{P} = \{\mathcal{P}_\theta \mid \theta \in \Theta \subset V\}$, где V не обязательно конечномерное.

Пример: $\mathfrak{P} = \{\mathcal{P}^{\otimes n} \mid \int_{\mathcal{X}} x \mathcal{P}(dx) = 0\}$

- семипараметрические, если $\mathfrak{P} = \{\mathcal{P}_\theta \mid \theta \in \Theta \subset \mathbb{R}^k \times V\}$.

Пример: линейная регрессия $Y = X\beta + \varepsilon$, $\beta \in \mathbb{R}^k$, $\mathbb{E}\varepsilon = 0$, $\mathbb{D}\varepsilon = \sigma^2$.

Если $D = [X_1, \dots, X_n]$ и X_i независимы и имеют одинаковое распределение \mathcal{P}_X , D называется **выборкой объема n** и обозначается $X_{[n]}$, \mathcal{P}_X — генеральная совокупность. В этом случае модель приобретает вид $\mathfrak{P} = \{\mathcal{P}^{\otimes n} \mid \mathcal{P} \in \mathfrak{P}_X\}$, где \mathfrak{P}_X — модель для \mathcal{P}_X .

1.4 Формула Байеса, априорное, апостериорное распределение

- Априорное распределение — наше ощущение относительно значения параметра до проведения эксперимента.
- Апостериорное распределение — ощущение после получения данных эксперимента.

def (Формула Байеса). Здесь p — вероятность, d — данные, θ — параметры.

$$p(\theta | d) = \frac{p(d | \theta) \cdot p(\theta)}{p(d)}.$$

- $p(\theta | d)$ — апостериорное распределение,
- $p(d | \theta)$ — правдоподобие,
- $p(\theta)$ — априорное распределение,
- $p(d)$ — вероятность данных.

1.5 Расстояние Кульбака-Лейблера, энтропия

Пусть мы принимаем случайные символы x_1, \dots, x_k , вероятность появления x_i равна p_i , записываем с помощью битовой строки длины l_i . Тогда средняя длина символа равна

$$l = \sum_{i=1}^k p_i \cdot l_i.$$

Чтобы минимизировать l , необходимо подобрать следующие $l_i = -\log_2 p_i$. И тогда средняя длина будет равна $H(x) := -\sum_{i=1}^k p_i \cdot \log_2 p_i$, эта величина называется двоичной энтропией сообщения. Аналогично можно брать любой другой логарифм, мы будем использовать натуральный.

Для непрерывной величины можно завести дифференциальную энтропию:

$$H(X) = - \int p(x) \log p(x) dx.$$

Пусть случайная величина X имеет функцию вероятности p , но мы кодируем символы, как-будто она имеет функцию вероятности q . Тогда средняя длина сообщения будет равна $-\sum_{i=1}^k p_i \cdot \log q_i$, эта величина называется **кросс-энтропией** $H(p \mid q)$ распределений p и q .

$H(p \mid q)$ всегда будет больше $H(p)$, так как $H(p)$ минимально.

def. Величина потери информации из-за использования q вместо p называется **расстоянием Кульбака-Лейблера** между p и q :

$$D_{KL}(p, q) = H(p \mid q) - H(p) = -\sum_{i=1}^k p_i \cdot \log \frac{q_i}{p_i}.$$

Для непрерывных величин все обобщается следующим образом

$$D_{KL} = -\int p_i \cdot \log \frac{q_i}{p_i}.$$

1.6 Статистика...

1.6.1 Статистика

Параметр или характеристика распределения — функционал от этого распределения.

def. Статистика — функция θ^* от данных d .

Пусть модель $\mathfrak{P}_{[n]} = \{\mathcal{P}^{\otimes n} \mid \mathcal{P} \in \mathfrak{P}\}$, искомая характеристика $\theta: \mathfrak{P} \rightarrow \mathbb{R}^k$.

1.6.2 Несмещенность

Чему равна оценка как случайная величина в среднем, если она равна характеристике?

def. Оценка Θ^* называется

- несмещенной, если $\forall \mathcal{P} \in \mathfrak{P}: \mathbb{E}\theta^*(X_{[n]}) = \theta(\mathcal{P})$, где $X_{[n]} \sim \mathcal{P}^{\otimes n}$,

- асимптотически несмещенной, если $\forall \mathcal{P} \in \mathfrak{P}: \mathbb{E}\theta^*(X_{[n]}) \rightarrow \theta(\mathcal{P})$.

Смещение — величина $b(\theta^*) = \mathbb{E}(\theta^*(X_{[n]})) - \theta(\mathcal{P})$.

Среднеквадратичная ошибка — величина $\text{MSE}(\theta^*) = \mathbb{E}(\theta^*(X_{[n]}) - \theta(\mathcal{P}))^2$.

В общем случае

$$\text{MSE}(\theta^*) = \mathbb{D}\theta^*(X_{[n]}) + b^2(\theta^*).$$

- Выборочное среднее как оценка матожидания — несмещенная оценка,
- Выборочная дисперсия как оценка дисперсии — асимптотически несмещенная,
- Исправленная выборочная дисперсия как оценка дисперсии — несмещенная оценка.

1.6.3 Состоятельность

def. Оценка θ^* называется

- состоятельной, если $\forall \mathcal{P} \in \mathfrak{P}: \theta^*(X_{[n]}) \xrightarrow{\mathbb{P}} \theta(\mathcal{P})$, где $X_{[n]} \sim \mathcal{P}^{\otimes n}$,
- сильно состоятельной, если $\theta^*(X_{[n]}) \xrightarrow{\text{п. н.}} \theta(\mathcal{P})$.

1.6.4 Асимптотическая нормальность

def. Оценка θ^* называется асимптотически нормальной с коэффициентом рассеивания (или просто дисперсией) $\sigma^2(\theta(\mathcal{P})) > 0$, если

$$\sqrt{n}(\theta^*(X_{[n]}) - \theta(\mathcal{P})) \xrightarrow{d} \eta \sim \mathcal{N}(0, \sigma^2(\theta^*(\mathcal{P}))).$$

В многомерном случае рассматривается ковариационная матрица вместо дисперсии.

- Выборочная дисперсия и второй момент — асимптотически нормальная оценка.
- Из асимптотической нормальности следует состоятельность.

1.6.5 Эффективность

Рассмотрим класс оценок $K = \{\hat{\theta}\}$ параметра θ .

def. Оценка $\theta^* \in K$ называется **эффективной в классе K** , если для любой другой оценки $\hat{\theta} \in K$ и для любого исследуемого параметра $\theta \in \Theta$ выполняется

$$\text{MSE}_\theta(\theta^*) \leq \text{MSE}_\theta(\hat{\theta}).$$

Класс несмещенных оценок

$$K_0 = \{\hat{\theta} \mid \mathbb{E}\hat{\theta} = \theta, \forall \theta \in \Theta\}.$$

def. Эффективная оценка θ^* , если эффективна в классе K_0 .

def. Асимптотически эффективной в классе K , если для любой оценки $\hat{\theta} \in K$ и для любого $\theta \in \Theta$ выполняется

$$\lim_{n \rightarrow \infty} \frac{\text{MSE}(\theta^*)}{\text{MSE}(\hat{\theta})}.$$

1.6.6 Робастность

def. Робастность — свойство оценки быть устойчивой к хвостам распределения.

Пусть F — распределение, $\{G_n\}$ — последовательность распределений, что

$$\|F - G_n\| := \sup_x |F(x) - G_n(x)| \rightarrow 0.$$

def. Характеристика θ обладает **качественной робастностью**, если $\theta(G_n) \rightarrow \theta(F)$

Пусть также δ_x — вырожденное распределение в точке x .

def. Загрязненное распределение — смесь $F_{x,\varepsilon} = (1 - \varepsilon)F + \varepsilon\delta_x$.

def. Функция влияния характеристики θ — величина

$$IF(x) = \lim_{\varepsilon \rightarrow 0+} \frac{\theta(F_{x,\varepsilon}) - \theta(F)}{\varepsilon}.$$

def. Характеристика θ называется B -робастной или инфинитезимально робастной, если $IF(x)$ ограничена.

def. Асимптотическая толерантность характеристики θ —

$$\tau = \inf \left\{ \varepsilon \mid \sup_x |\theta(F_{x,\varepsilon}) - \theta(F)| = \infty \right\}.$$

1.6.7 Достаточность

def. Статистика $T(x) = \{T_1(x), \dots, T_m(x)\}$ называется достаточной, если для всех

- $\theta \in \Theta$,
- $B \in \mathfrak{P}(\mathbb{R}^n)$ и
- $t = (t_1, \dots, t_m)$

условная вероятность $\mathbb{P}(X_{[n]} \in B \mid T(X_{[n]}) = t)$ не зависит от θ .

То есть информация о θ в выборке полностью содержится в значении $T(x_{[n]})$.

thm (факторизации). $T(x)$ достаточна, тогда существуют функции g и h , что

$$p(X_{[n]} = x_{[n]} \mid \theta) = g(T(x_{[n]}), \theta)h(x_{[n]}),$$

где p — вероятность или плотность.

1.6.8 Полнота

def. Статистика T называется полной, если для любой измеримой g верно следствие

$$\forall \theta \in \Theta: \mathbb{E}g(T(X_{[n]})) \equiv 0 \quad \implies \quad g(T(X_{[n]})) \stackrel{n.n.}{=} 0.$$

1.7 Теоремы Колмогорова-Блэкуэлла-Рао и Лемана-Шеффе

thm (Колмогорова-Блэкуэлла-Рао). Пусть θ^* — оценка параметра θ , T — достаточная статистика. Тогда

$$\text{MSE}(\theta^*) \geq \text{MSE}(\mathbb{E}(\theta^* | T)).$$

thm (Лемана-Шеффе). Пусть θ^* — оценка параметра θ , T — достаточная и полная статистика. Тогда $\mathbb{E}(\theta^* | T)$ — единственная эффективная оценка в классе оценок со смещением $b(\theta^*)$.

1.8 Доверительный интервал

Пусть есть модель $\mathfrak{P}_{[n]} = \{\mathcal{P}^{\otimes n} \mid \mathcal{P} \in \mathfrak{P}\}$ и $\theta: \mathfrak{P} \rightarrow \mathbb{R}^k$ — искомая характеристика.

def. Доверительный интервал (точный доверительный интервал) с уровнем доверия γ — пара статистик (θ_L^*, θ_R^*) , такая что для любого $\mathcal{P} \in \mathfrak{P}$ и $X_{[n]} \sim \mathcal{P}^{\otimes n}$

$$\mathbb{P}(\theta_L^*(X_{[n]}) \leq \theta(\mathcal{P}) \leq \theta_R^*(X_{[n]})) = \gamma.$$

Интервал называется

- асимптотическим, если

$$\mathbb{P}(\theta_L^*(X_{[n]}) \leq \theta(\mathcal{P}) \leq \theta_R^*(X_{[n]})) \xrightarrow{n \rightarrow \infty} \gamma.$$

- центральным, если

$$\mathbb{P}(\theta_L^*(X_{[n]}) > \theta(\mathcal{P})) = \mathbb{P}(\theta_R^*(X_{[n]}) < \theta(\mathcal{P})).$$

- левым, если

$$\mathbb{P}(\theta_L^*(X_{[n]}) > \theta(\mathcal{P})) = 0.$$

- правым, если

$$\mathbb{P}(\theta_R^*(X_{[n]}) < \theta(\mathcal{P})) = 0.$$

1.9 Бутстреп

1.9.1 Параметрический бутстреп

Если работаем с параметрической моделью, можем заменить $X = X(\theta)$ не на X^* , а на $X(\theta^*)$ и сэмплировать из этого распределения.

1.9.2 Непараметрический бутстреп

Рецепт

1. изготoвим N выборок $x_{[n],1}^*, \dots, x_{[n],N}^*$ из эмпирического распределения (рандом с возвращением)
2. вычисляем $\theta_i^b = \theta^*(x_{[n],i}^*)$, получаем бутстреповскую выборку $\theta_{[N]}^b$,
3. по бутстреповской выборке оцениваем, что нужно.

Ограничения

- θ^* — plug-in оценка
- θ^* — достаточно гладкая (обычно дифференцируема)
- у X достаточно много моментов (обычно конечная дисперсия)
- нужно генерировать большие выборки
- на очень больших данных трудозатратен
- на маленьких данных велика неустраняемая ошибка

1.10 Гипотеза, альтернатива...

Пусть \mathfrak{P} — модель.

1.10.1 Гипотеза и альтернатива

def. Гипотеза — утверждение вида $H: \mathcal{P}_X \in \mathfrak{P}_0 \subset \mathfrak{P}$.

Если $|\mathfrak{P}_0| = 1$, гипотеза называется *простой*, иначе *сложной*.

Нулевая гипотеза — гипотеза H_0 , которую мы хотим проверить. Проверка гипотезы — процесс принятия решения о том, противоречит ли она наблюдаемой выборке данных.

Альтернатива — гипотеза H_1 , которая отражает, какие отклонения от нулевой гипотезы нам интересны.

1.10.2 Критерий

def. Нерандомизированный критерий (критерий) — отображение $\varphi: d \rightarrow \{\text{принимаем, отвергаем}\} = \{H_0, H_1\} = \{0, 1\}$.

Часто критерий устроен так: имеется

- статистика критерия T и

- критическое множество C , и

$$\varphi(d) = [T(d) \in C] = [d \in T^{-1}(C)].$$

def. Рандомизированный критерий — отображение $\varphi: d \rightarrow [0, 1]$. Значение на данных d определяется как реализация случайной величины $D(\varphi(d))$.

Пусть мы согласны отвергать нулевую гипотезу при условии, что она верна, но хотим делать это не очень часто. Пусть зафиксирован *уровень значимости*

$$\alpha := \mathbb{P}(\varphi(D) = 1 \mid H_0),$$

который обычно является *параметром критерия*, то есть, задавая его, мы определяем *критическое множество* C_α такое, что

$$\mathbb{P}(T(D) \in C_\alpha \mid H_0) = \alpha.$$

Таким образом, для одного критерия определено семейство критических областей $\{C_\alpha \mid \alpha \in [0, 1]\}$, где обычно $C_\alpha \subset C_{\alpha'}$, если $\alpha < \alpha'$.

def. *Уровень значимости* — параметр критерия, который регулирует, насколько часто мы будем отвергать нулевую гипотезу при условии, что она верна.

1.10.3 p-value

Хотим оценить, насколько гипотеза противоречит наблюдаемым данным.

def. p-value — характеристика противоречия гипотезы наблюдаемым данным:

$$\text{p-value} := \arg \min \{ \alpha \in [0, 1] \mid T(d) \in C_\alpha \}.$$

Другими словами, p-value — минимальное значение уровня значимости для данного значения статистики критерия, при котором H_0 может быть отвергнута.

Чем меньше p-value, тем больше гипотеза противоречит данным.

1.10.4 Ошибки разных родов

def. Ошибка первого рода — событие $\varphi(D) = 1 \mid H_0$. Если уровень значимости совпадает с вероятностью ошибки первого рода, То критерий называется **точным**.

Уровень значимости — вероятность ошибки первого рода.

def. Ошибка второго рода β — событие $\varphi(D) = 0 \mid H_1$, не отклонили нулевую гипотезу при условии, что была верна альтернатива.

Мощность критерия — вероятность $1 - \beta$ отклонить H_0 при условии, что верна H_1 .

Для заданного уровня значимости мы хотим иметь как можно более мощный критерий.

1.10.5 Свойства критериев

def. Несмещенность — мощность всегда не меньше ошибки первого рода, критерий не отдает предпочтение альтернативе. $1 - \beta \geq \alpha$ для всех простых гипотез из \mathfrak{P}_0 и простых альтернатив из \mathfrak{P}_1 .

def. Состоятельность — $\beta \xrightarrow{n \rightarrow \infty} 0$ для всех простых альтернатив из \mathfrak{P}_1 .

def. Асимптотичность — $\alpha \xrightarrow{n \rightarrow \infty}$ для всех простых гипотез из \mathfrak{P}_0 .

def. Наиболее мощный критерий для данного уровня значимости α_0 и простой альтернативы — такой критерий φ_1 , что для любого критерия φ_2 такого, что $\alpha(\varphi_2) \leq \alpha_0$:

$$\beta(\varphi_1) \leq \beta(\varphi_2).$$

1.10.6 Размер эффекта

Во многих случаях важна не только информация о p-value, но и величина наблюдаемого эффекта. Размеры эффекта бывают разные, использование того или иного размера эффекта зависит от контекста.

Вместо сравнения p-value с уровнем значимости для принятия статистического решения можно считать размер эффекта, сравнивать с минимальным практически интересным.

1.11 Постановка гипотезы согласия. Критерии Колмогорова и Андерсона-Дарлинга

1.11.1 Постановка гипотезы согласия

def. Гипотеза согласия — гипотеза о соответствии эмпирического распределения теоретическому распределению вероятностей.

Критерии для гипотез согласия бывают

- общие — применимые к любому предполагаемому распределению выборки,
- специальные — применимые к гипотезам, формулирующие согласие с определенным свойством распределений;
- для простых гипотез,
- для сложных гипотез.

1.11.2 Критерий Колмогорова

Сравнивает эмпирическое и истинное распределение. Для простой гипотезы.

Пусть F_0 непрерывна на \mathbb{R} . Определим статистику Колмогорова:

$$D_n(x_{[n]}) = \sup_{x \in \mathbb{R}} |F_n^* - F_0(x)|.$$

- Если H_0 верна, то $D_n(X_{[n]}) \xrightarrow{\text{п.н.}} 0$;
- Если H_0 неверна, то $D_n(X_{[n]}) \xrightarrow{\text{п.н.}} \sup_{x \in \mathbb{R}} |F_X(x) - F_0(x)| > 0$.

1.11.3 Критерий Андерсона-Дарлингга

Для простой гипотезы.

Определим статистику критерия Андерсона-Дарлингга:

$$\begin{aligned} A^2 &= n \int_{\mathbb{R}} \frac{(F_n^*(x) - F_0(x))^2}{F_0(x)(1 - F_0(x))} dF_0(x) = \\ &= -n - \sum_{i=1}^n \frac{2i-1}{n} [\ln F_0(X_{(i)} | \theta) + \ln (1 - F_0(X_{(n+1-i)} | \theta))] \end{aligned}$$

Статистика A^2 при выполнении H_0 и непрерывности F_0 подчиняется табличному распределению. $C_\alpha = (a_{1-\alpha}^2, \infty)$.

1.12 Постановка гипотезы о параметрах, проверка через доверительные интервалы, z-test, t-test, бутстреп из нулевой гипотезы

1.12.1 Постановка гипотезы о параметрах

Пусть θ — параметр ($X \sim F(x, \theta)$) или характеристика ($\theta = \varphi(F_x)$) распределения.

Нулевая гипотеза: $H_0: \theta = \theta_0$. Типичные альтернативы:

- $H_1: \theta = \theta_1 \neq \theta_0$,
- $H_>: \theta > \theta_0$,
- $H_<: \theta < \theta_0$,
- $H_{\neq}: \theta \neq \theta_0$.

Усредненный рецепт:

1. Выбираем оценку θ^* параметра θ , распределение которой приближенно известно при данном θ .
2. В зависимости от альтернативы строим критическое множество:
 - $H_1: \theta = \theta_1 > \theta_0$ или $H_>$, то $C_\alpha = (\theta_{1-\alpha}^*, \infty)$ ¹ — правое критическое множество;
 - $H_1: \theta = \theta_1 < \theta_0$ или $H_<$, то $C_\alpha = (-\infty, \theta_\alpha^*)$ — левое критическое множество;
 - H_{\neq} , то $C_\alpha = (-\infty, \theta_{\frac{\alpha}{2}}^* \cup (\theta_{1-\frac{\alpha}{2}}^*, \infty)$ — двустороннее критическое множество.
3. Если $\theta^* \in C_\alpha$, то гипотезу можно отклонить, иначе — нельзя.

1.12.2 Проверка через доверительные интервалы

Усредненный рецепт:

1. В зависимости от альтернативы строим доверительный интервал с уровнем доверия $\gamma = 1 - \alpha$:
 - $H_1: \theta = \theta_1 > \theta_0$ или $H_>$, то (θ_L^*, ∞) — правый доверительный интервал;
 - $H_1: \theta = \theta_1 < \theta_0$ или $H_<$, то $(-\infty, \theta_R^*)$ — левый доверительный интервал;
 - H_{\neq} , то (θ_L^*, θ_R^*) — центральный доверительный интервал.

¹Здесь θ_x^* — квантиль уровня x распределения $\theta^* | H_0$

1.12.3 z-test

Пусть $X \sim \mathcal{N}(\mu, \sigma^2)$, μ неизвестно, σ^2 известно.

Если H_0 верна, то $Z = \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma} \sim \mathcal{N}(0, 1)$ и $\bar{X} \sim N(\mu_0, \frac{\sigma^2}{n})$.

В зависимости от альтернативы подбираем критическую область:

	$\theta_1 > \theta_0, H_>$	$\theta_1 < \theta_0, H_<$	H_{\neq}
C_α	$(\mu_0 + z_{1-\alpha} \frac{\sigma}{\sqrt{n}}, \infty)$	$(-\infty, \mu_0 + z_\alpha \frac{\sigma}{\sqrt{n}})$	$\mathbb{R} \setminus (\mu_0 \pm z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}})$
p-value	$1 - \Phi^{-1}(z)$	$\Phi^{-1}(z)$	$2(1 - \Phi^{-1}(z))$

Таблица 1.1: Критическая область для альтернативы

1.12.4 t-test

Пусть $X \sim \mathcal{N}(\mu, \sigma^2)$, μ неизвестно, σ^2 неизвестно.

Если H_0 верна, то $T = \frac{\sqrt{n}(\bar{X} - \mu_0)}{s} \sim T(n - 1)$.

В зависимости от альтернативы подбираем критическую область:

	$\theta_1 > \theta_0, H_>$	$\theta_1 < \theta_0, H_<$	H_{\neq}
C_α	$(\mu_0 + t_{1-\alpha} \frac{s}{\sqrt{n}}, \infty)$	$(-\infty, \mu_0 + t_\alpha \frac{s}{\sqrt{n}})$	$\mathbb{R} \setminus (\mu_0 \pm t_{1-\frac{\alpha}{2}} \frac{s}{\sqrt{n}})$
p-value	$1 - T^{-1}(t)$	$T^{-1}(t)$	$2(1 - T^{-1}(t))$

Таблица 1.2: Критическая область для альтернативы

1.12.5 Бутстреп из нулевой гипотезы

Пусть мы хотим проверить гипотезу $H_0: \mathbb{E}X = \theta_0$.

Рецепт:

1. Назначим каждому наблюдению x_i в выборке вероятность p_i .
2. Из пар (x_i, p_i) изготовим дискретное распределение F_p^* .

3. Подберем p_i так, чтобы с одной стороны $\bar{x} = \theta_0$, а с другой p_i максимизировали правдоподобие выборки $\mathcal{L}(p \mid x_{[n]}) = p_1 p_2 \dots p_n$.
4. Бутстрепим кучу выборок из получившегося F_p^* , считаем по ним выборочное среднее.
5. Построим критическое множество в зависимости от альтернативы и проверим, лежит ли в нем выборочное среднее исходной выборки.